precical_statistics

January 24, 2022

[194]:
```
using CSV;
using PyCall;
using PyPlot;
using Printf;
using DataFrames, FreqTables
using HypothesisTests

np  = pyimport("numpy");
sns = pyimport("seaborn");
ss  = pyimport("scipy.stats");
wrg = pyimport("warnings");
pd  = pyimport("pandas");
```

[200]:
```
ps = pyimport("pyspark.pandas");
pd = pyimport("databricks.koalas");
tree = pyimport("sklearn.tree");
layers = pyimport("keras.layers");
models = pyimport("keras.models");
prepro = pyimport("sklearn.preprocessing");
utils  = pyimport("sklearn.utils");
metrics = pyimport("sklearn.metrics");
model_selection = pyimport("sklearn.model_selection");
```

[2]:
```
wrg.filterwarnings("ignore")
```

1 1.0. Capítulo 1

1.1 1.1. Correlação

1.1.1 1.1.1. R de Pearson

O coeficiente de correlação de pearson é muitas vezes o primeiro coeficiente estudado ou abordado em livros. São ditos os dados que são positivamente correlacionados quando os valores de **x** acompanham os valores de **y** e negativamente correlacionados se os valores altos de **x** acompanharem os valores baixos de **y**.**Causalidade** a variável **x** é a causa da variável **y**, logo por exemplo a correlação entre número de vendas e clientes é positiva, mas não quer dizer que quantos mais clientes existem mais vendas eu tenha.Ex: O número de consumo de **margarina** e o número de **divórcios** em Maine.

Fórmula do coeficiente de pearson.

$$r = \frac{n(\sum xy) - (\sum x)(\sum y))}{\sqrt{(n \sum (x^2) - (\sum x)^2)\ (n \sum (y^2) - (\sum y)^2)}}$$

[4]:
```
function plot_linear(a, b, d, r1, r2)
    fig, ax = plt.subplots( figsize=(6, 5) );

    x = np.arange( r1, r2, 1 )
    y = a * x .+ b + np.random.normal( 0, d, length(x) );

    r = (length(x)sum(x .* y) - (sum(x)sum(y))) / (sqrt((length(x)sum(x.^2) -
 ↪(sum(x))^2) * (length(y)sum(y.^2) - (sum(y))^2)))

    ax = sns.regplot(x, y, color="r")
    if r >= 0
        ax.set_title(("Correlação Positiva: " * string(round(r, digits=4))))
    else
        ax.set_title(("Correlação Negativa: " * string(round(r, digits=4))))
    end
end;
```

[7]:
```
plot_linear(2, 2, 3, -10, 10);
```

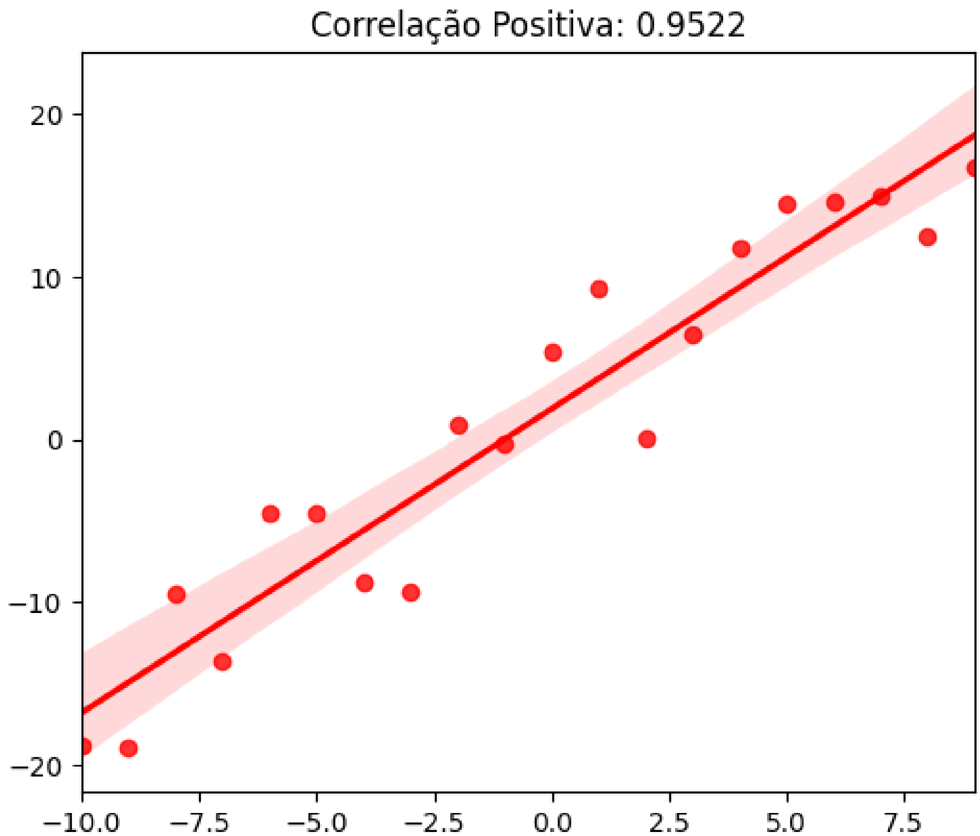

[8]:
```
plot_linear(-5, 40, 50, -13, 140);
```

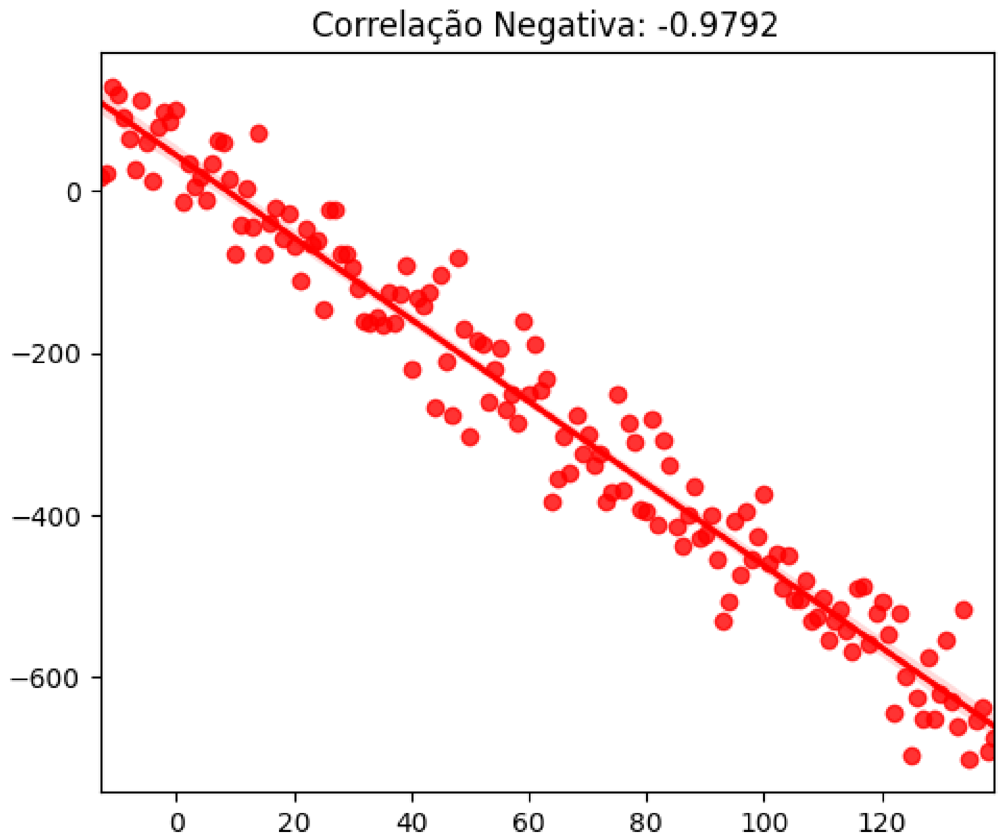

1.1.2 1.1.2. Rho de spearman

Robusto contra outliers e calculado em relação ao ranqueamento ou ordens dos dados, também mede relações lineares e não lineares.

$$r_s = 1 - \frac{6 \sum d^2}{n^3 - n}$$

[95]:
```
function spearman_plot( size, power )
    log_a = [log1p(abs(j-10)) for j in 1:size]
    log_b = [log1p(j)^power for j in 1:size]
    cor, _ = ss.spearmanr( log_a, log_b );

    fig, ax = plt.subplots( figsize=(5, 5) )
    ax.plot( log_a, color="b", linestyle="--", label="Log - 6" )
    ax.plot( log_b, color="r", linestyle="--", label="Negative Log" )
    ax.set_title( "Correlação: " * string(round(cor, digits=4)) )
    plt.legend();
end;
```

[96]:

```
spearman_plot( 100, -3 );
```

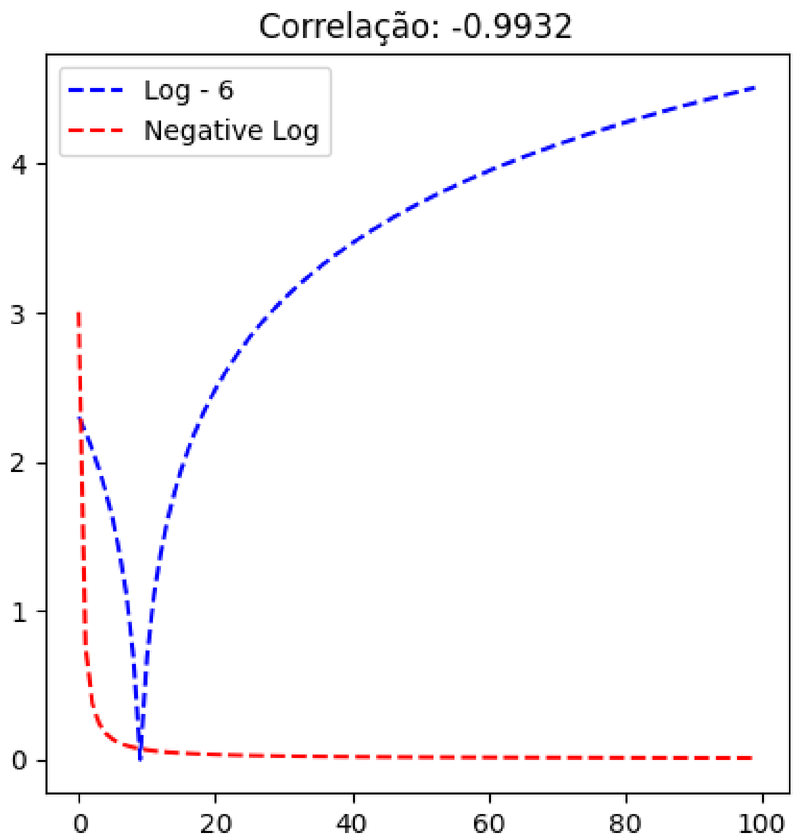

[97]:

```
spearman_plot( 300, 3 );
```

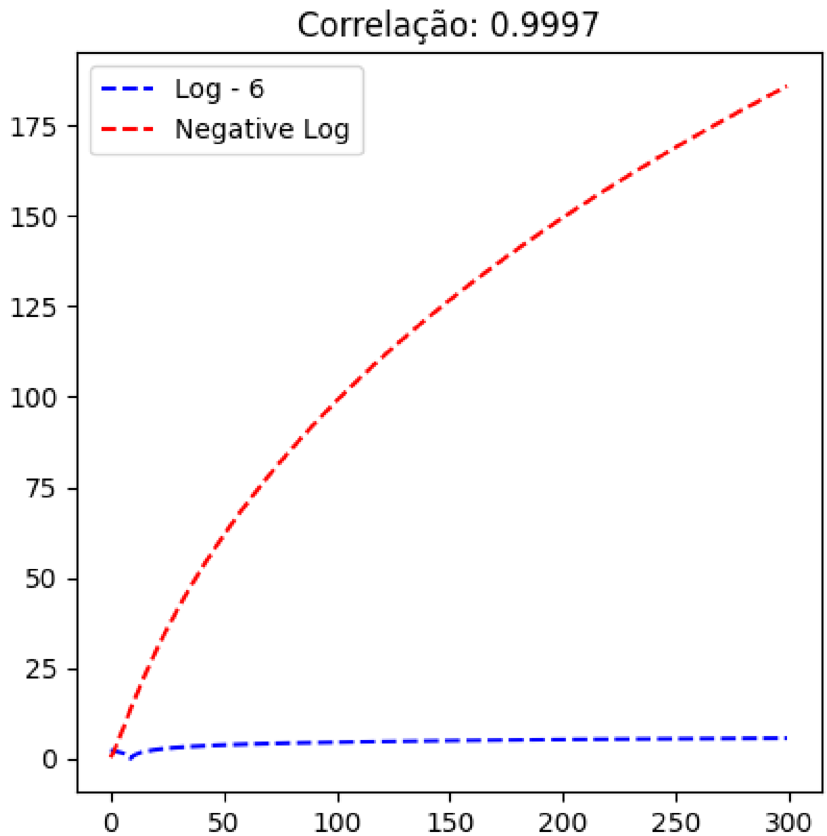

1.1.3 1.1.4. V de Cramér

O V de cramér basicamente serve para calcular a correlação entre variaveis categoricas.

Existe a versão corrigida da fórmula de cramér que esta abaixo, k e r são as dimensões da matriz.

$$V = \sqrt{\frac{\varphi^2 \ ou \ X^2/n}{min(k-1, r-1)}}$$

$$\varphi^2 = max(0, \varphi^2 - \frac{(k-1)-(r-1)}{n-1}$$

$$cor \ k = k - \frac{(k-1)^2}{n-1}$$

$$cor \ r = r - \frac{(r-1)^2}{n-1}$$

[226]:
```
function cramer_v( x, y )
    cm = freqtable(x, y)
```

```
    n  = sum(cm)
    r, k = size(cm)

    chi2 = ChisqTest( cm ).stat
    chi2corr = max( 0, chi2 - ((( k-1 ) * ( r-1 )) / ( n-1 ) ))

    kcorr = k - ((( k-1 )^2) / ( n-1 ))
    rcorr = r - ((( r-1 )^2) / ( n-1 ))

    return sqrt( ( chi2corr / n ) / ( min( kcorr - 1, rcorr - 1 ) ) )
end;

df = DataFrame(CSV.File("data/store.csv"))
df = hcat(df[:, 2:3], df.StoreType )
df = rename(df, Dict("x1" => "State"));

# Rename Rows
df.Assortment = [replace(i, "a" => "BASIC") for i in df.Assortment];
df.Assortment = [replace(i, "b" => "EXTRA") for i in df.Assortment];
df.Assortment = [replace(i, "c" => "EXTENDED") for i in df.Assortment];

# Generate FataFrame
results = []
data = DataFrame()

for i in ["StoreType", "Assortment", "State"]
    a = cramer_v( Array(df.StoreType), Array(df[:, i]) )
    b = cramer_v( Array(df.Assortment), Array(df[:, i]) )
    c = cramer_v( Array(df.State), Array(df[:, i]) )

    corr = Dict(i => [a, b, c])
    append!(results, corr)
end

df2 = DataFrame( results ) # Plotar um Mapa de Calor / Heatmap
```

[226]:

	StoreType	Assortment	State
	Float64	Float64	Float64
1	1.00135	0.54068	1.00135
2	0.54068	1.0009	0.54068
3	1.00135	0.54068	1.00135

1.2 1.2. Dois Gráficos de Densidade

Hexagonal Binning relaciona as duas variaveis aleatorias normais em hexágonos, mesma coisa que o Histograma.Kernel Density Estimate, Análogo análogo ao Hexagonal, porem em densidades com curvas.

[205]:
```
plt.hexbin( np.random.randn(20000), np.random.randn(20000), gridsize=30,␣
↪cmap="gist_heat" );
```

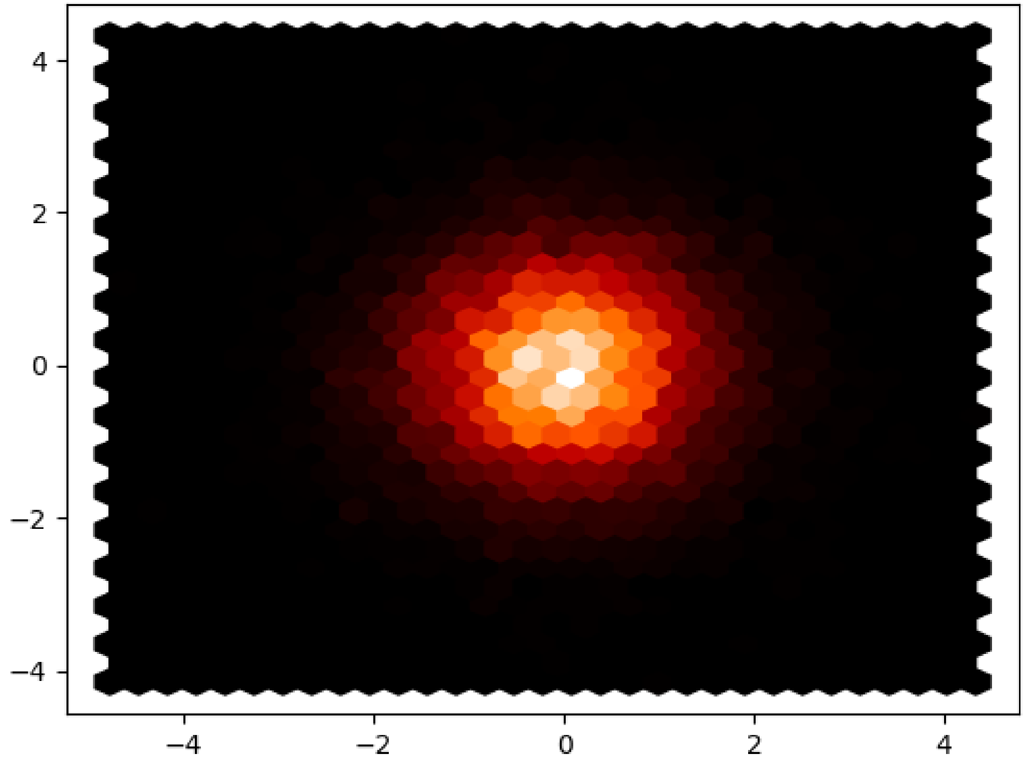

[207]:
```
sns.kdeplot(np.random.randn(20000), np.random.randn(20000) );
```

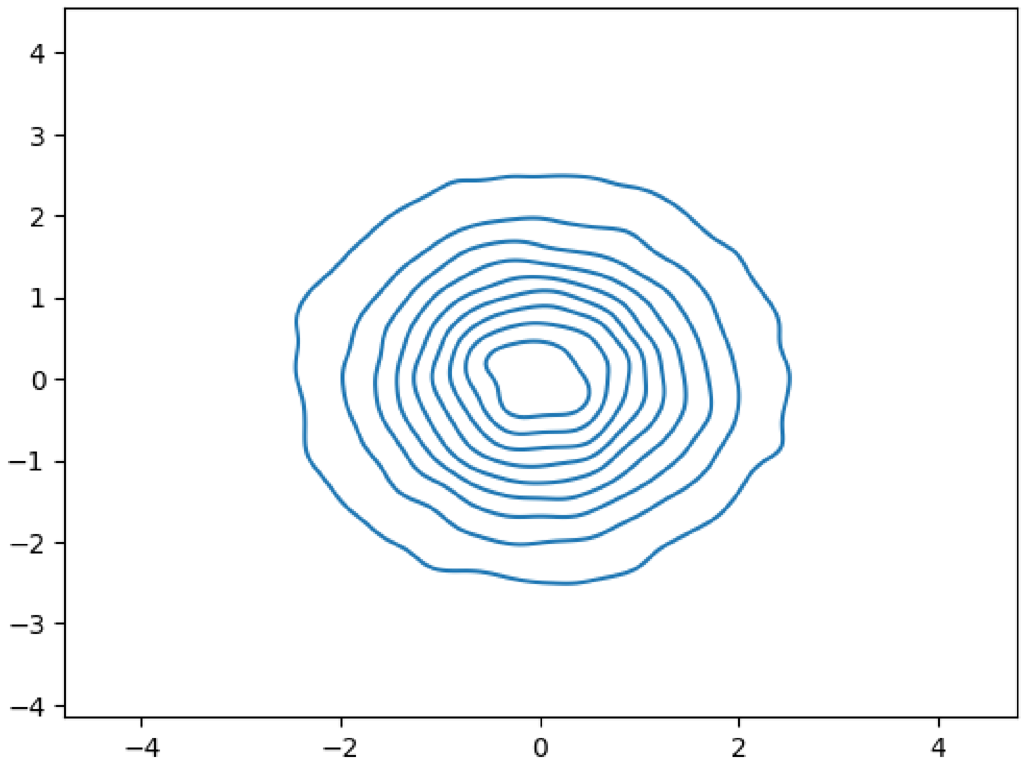

2 2.0. Capítulo 2

2.1 2.1. Distribuição de Amostragem de uma Estatística

A distribuição de uma estatística amostral como a média costuma ser mais regular e campanular do que a distribuição dos proprios dados quanto maior a amostra em que a estatística se baseia. Além disso, quanto maior a amostra, mais estreita é a distribuição da estatística amostral. “Tende a Normal”…

[15]:
```
df = pd.read_csv("data/loans_income.csv");
```

[16]:
```
sample = df.sample(1000)

sample_of_5 = pd.DataFrame( Dict("income" => [df["x"].sample(5).mean() for _ in␣
↪1:1000],
                                "type" => "mean_of_5") )

sample_of_10 = pd.DataFrame( Dict("income" => [df["x"].sample(10).mean() for _␣
↪in 1:1000],
                                "type" => "mean_of_10") )
```

```
sample_of_20 = pd.DataFrame( Dict("income" => [df["x"].sample(20).mean() for _
↪in 1:1000],
                                   "type" => "mean_of_20") )

result = pd.concat([sample, sample_of_5, sample_of_10, sample_of_20]);
```

[21]:
```
PyPlot.subplot(2, 1, 1);
sns.histplot( sample, kde=true, element="step" );

PyPlot.subplot(2, 1, 2);
sns.histplot( sample_of_5, kde=true, element="step" );
```

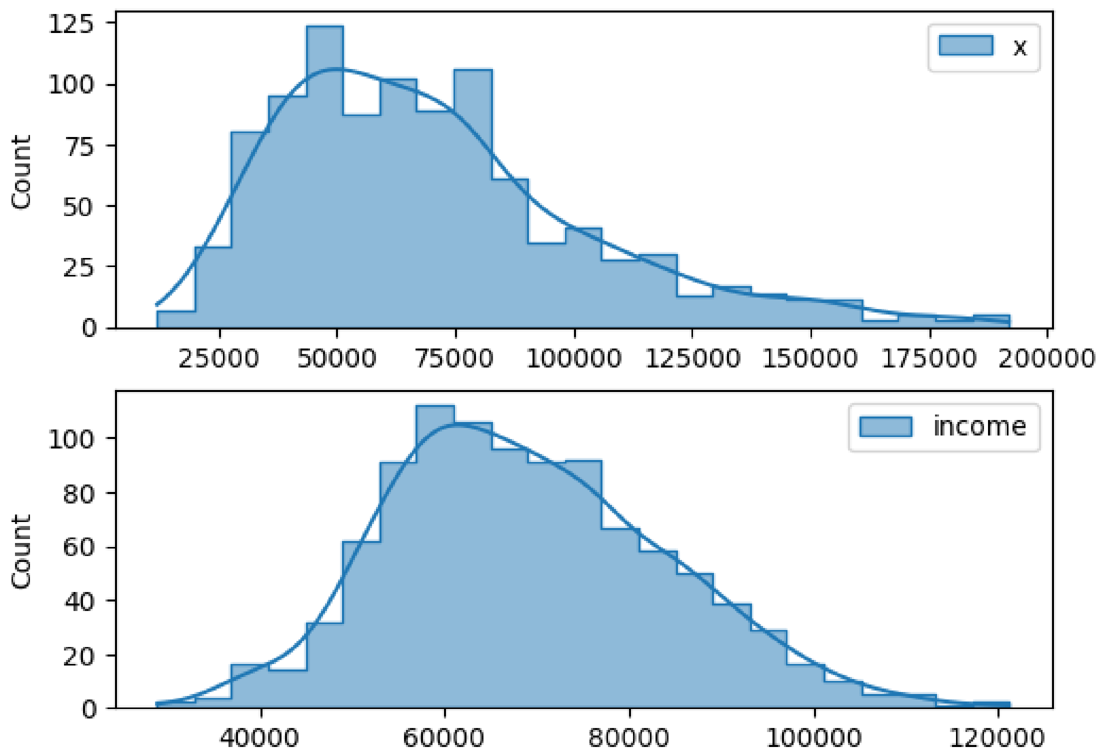

[20]:
```
PyPlot.subplot(2, 1, 1);
sns.histplot( sample_of_10, kde=true, element="step" );

PyPlot.subplot(2, 1, 2);
sns.histplot( sample_of_20, kde=true, element="step" );
```

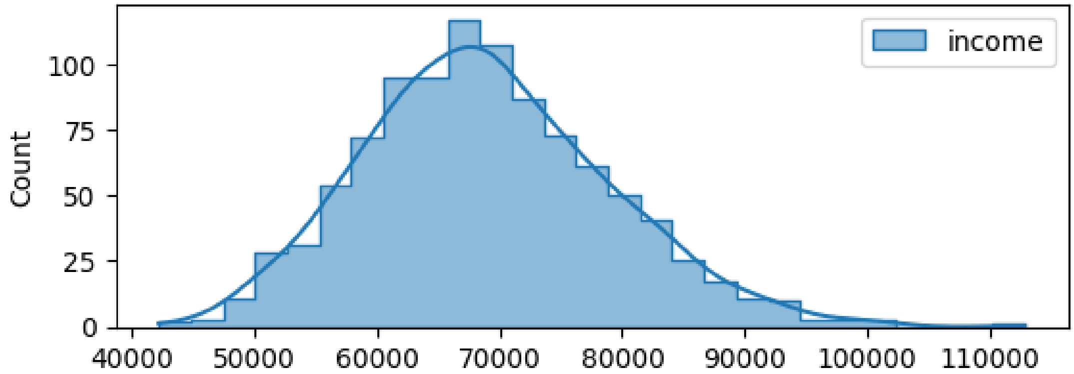

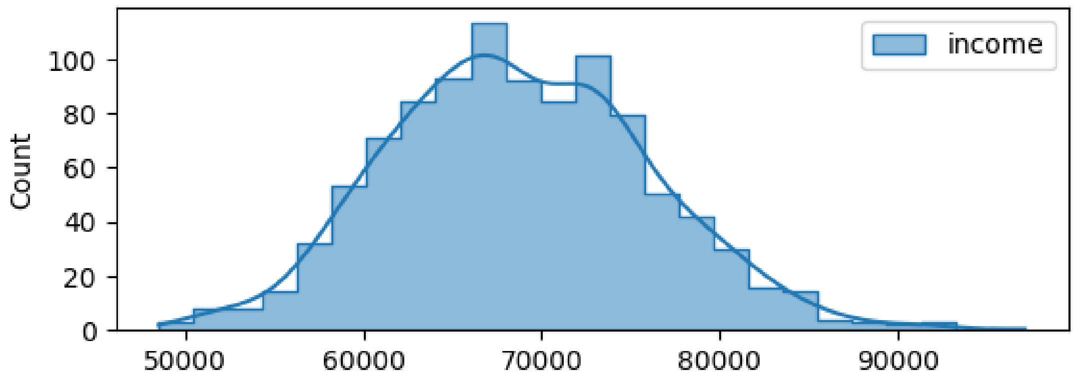

2.2 2.2. O Bootstrap

O bootstrap é uma forma eficiente e eficaz de estimar a distribuição amostral de uma estatística ou de parâmetros de modelo.Conceitualmente pode-se imaginar o Bootstrap como uma replicação da amostra original várias vezes de modo a ter uma população hipotética que representa todo o conhecimento da amostra original só que maior.Logo amostramos com reposição, dessa forma cria-se efetivamente uma população infinita na qual a probabilidade de um elemento ser extraído continua a mesma de extração por extração.Com os resultados é possível encontrar um intervalo de confiança.

2.2.1 2.2.1. Sem Bootstrap

[24]:
```
# Load and Prepare Dataset
df = DataFrame(CSV.File("data/diabetes.csv"));

x = df[:, 1:8];
x = hcat(x[:, 1], x[:, 2], x[:, 3], x[:, 4], x[:, 5], x[:, 6], x[:, 7]);

y = df[:, 9];

# Transform Variables
mms = prepro.MinMaxScaler()
```

```
x = mms.fit_transform( x );

# Split Dataset
x_train, x_test, y_train, y_test = model_selection.train_test_split( x, y,␣
↪train_size=0.9 );
```

[21]:
```
# Simple Logistic Regression
model = models.Sequential()
model.add( layers.Dense( 1, activation="sigmoid") )
model.compile( optimizer="sgd", loss="binary_crossentropy",␣
↪metrics=["accuracy"])
```

[22]:
```
history = model.fit( x_train, y_train, epochs=2000, verbose=0 );
test = model.evaluate( x_test, y_test );
```

```
3/3 [==============================] - 0s 2ms/step - loss: 0.5010 - accuracy:
0.7143
```

[117]:
```
PyPlot.plot( history.history["loss"] );
```

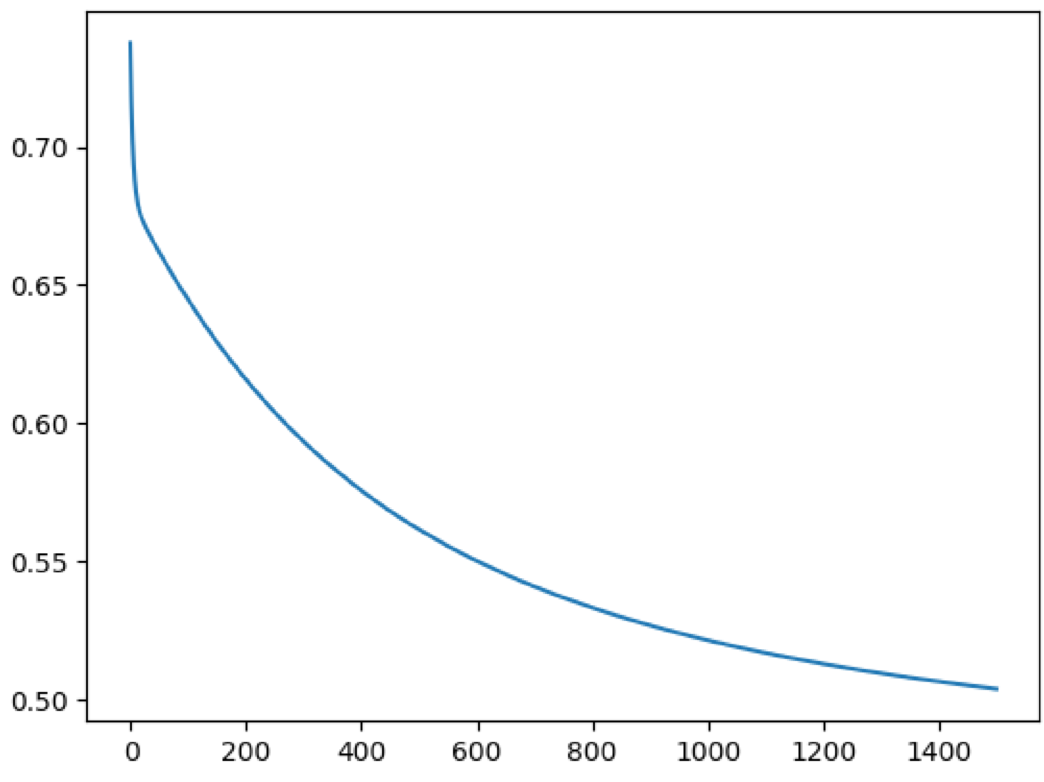

Conclusão

[116]:
```
@printf "Accuracy %.2f%%" maximum(history.history["accuracy"])*100
```

```
Accuracy if 77.71%
```

2.2.2 2.2.1. Com Bootstrap

[25]:
```
# Configuration of Bootstrap
n_inter = 1000
n_size  = trunc(Int, (768 * 0.5))
stats   = []

# Set Up Data
df = hcat(df[:, 1], df[:, 2], df[:, 3], df[:, 4], df[:, 5], df[:, 6], df[:, 7],␣
 ↪df[:, 8], df[:, 9])

for i in 1:n_inter
    sample = utils.resample( df, n_samples=n_size );
    y = sample[:, 9];
    x = sample[:, 1:8];

    x = mms.fit_transform( x );

    # Split Dataset
    x_train, x_test, y_train, y_test = model_selection.train_test_split( x, y,␣
 ↪train_size=0.9 );

    model = tree.DecisionTreeClassifier() # Decision Tree, dont NN.
    model.fit( x_train, y_train )

    prediction = model.predict( x_test )
    score = metrics.accuracy_score( y_test, prediction )

    append!(stats, score)
end
```

[106]:
```
plt.hist( stats, color="r", linewidth=2, histtype="step", bins=20 );
plt.vlines( np.mean( stats ), ymin=n_size-100, ymax=1., color="k",␣
 ↪linestyle="--", label="Mean" );
plt.legend();
```

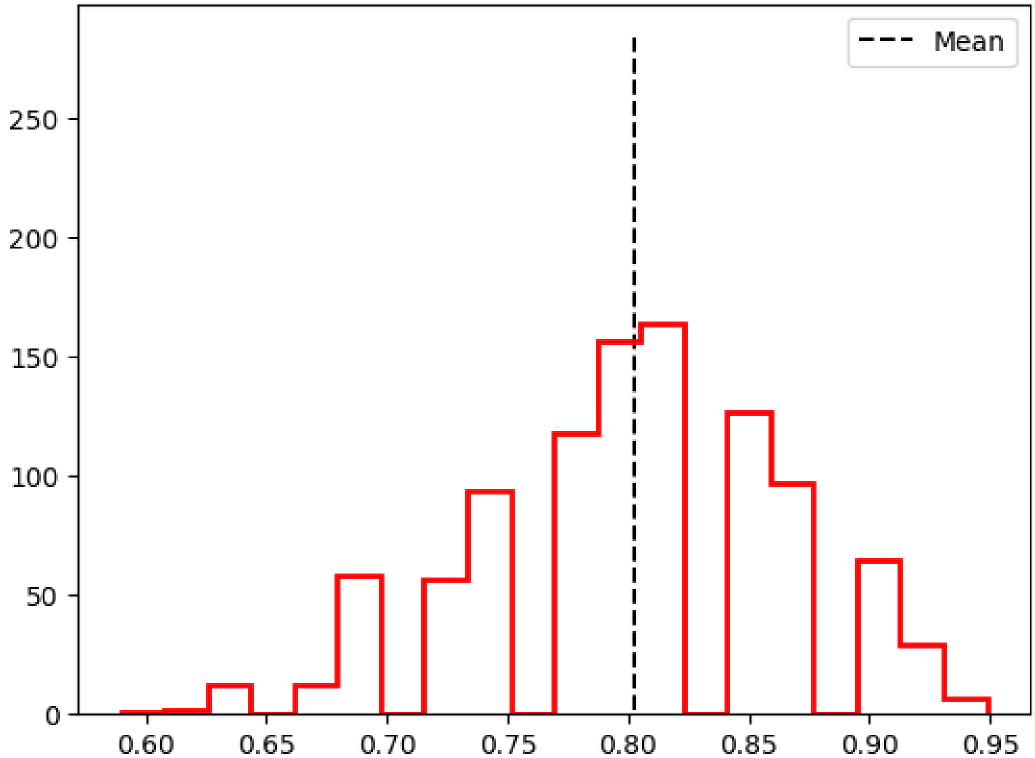

Conclusão

[110]:
```
  = 0.95

p = ((1.0 -  )/2.0)*100
lower = np.percentile(stats, p)*100

p = (  + (1.0 -  )/2.0) *100
max = np.percentile(stats, p)*100

@printf "%.0f%% Confidence Intervals %.2f%% and %.2f%%"  *100 lower max
```

```
95% Confidence Intervals 66.67% and 92.31%
```

2.3 2.3. Distribuições

2.3.1 2.3.1 Distribuição Binomial

A distribuição Binomial é, vamos dizer assim uma continuação da distribuição de Bernoulli, onde a distribuição de Bernoulli trabalha somente com duas possibilidades, ou 1 geralmente chamado de evento de sucesso ou 0 de fracasso contendo as probabilidades desses eventos ao lado.

[17]:
```
bernoulli = pd.DataFrame([["Azul", 0.35], ["Vermelho", 0.65]]);
bernoulli.columns = ["X", "Probabilidade"];
bernoulli
```

[17]:
```
PyObject          X  Probabilidade
0       Azul         0.35
1   Vermelho         0.65
```

Formula da Distribuição Binomial

$$P(r/n,p) = \binom{n}{r} \cdot p^r \cdot (1-p)^{n-r}, onde \binom{n}{r} = C_{nk} = \frac{n!}{r! \cdot (n-r)!}$$

- r: Eventos de Interesse.
- n: Repetições.
- p: Probabilidade do Evento.

A média da distribuição binomial é dada pela formula: $n \cdot p$A variância da distribuição binomial é dada pela formula: $\sqrt{n \cdot p \cdot (1-p)}$

[16]:
```
P(r, n, p) = (factorial(n) / (factorial(r) * factorial(n-r))) * (p^r) * ((1 -␣
↪p)^(n-r));
```

Qual é a probabilidade de sair 3 caras em 4 jogadas e a probabilidade de cada cara é $\frac{1}{2}$

$$P(2/4, \frac{1}{2}) = 6 \cdot (\frac{1}{2})^2 \cdot (\frac{1}{2})^2 = \frac{6}{16}$$

[18]:
```
@printf "A probabilidade de sair três caras em quatro jogadas é: %.3f%% " P(2,␣
↪4, .5)*100
```

```
A probabilidade de sair três caras em quatro jogadas é: 37.500%
```

Qual é a chance de 3 pessoas que eu ligar das 10 entrarem em churn sabendo que a probabilidade de uma pessoa em churn na base de dados é 0.15%?

[19]:
```
@printf "A probabilidade de 3 das 10 pessoas ligadas entrarem em churn é: %.
↪3f%%" P(3, 10, .15)*100
```

```
A probabilidade de 3 das 10 pessoas ligadas entrarem em churn é: 12.983%
```

Confome a probabilidade tende a o equilibrio, ou seja, .5% de cair cara ou coroa, logo a distribuição parece uma Normal.

[1012]:
```
prob  = [0.1, 0.5, 0.9]
color = ["r", "g", "b"]
label = ["Prob: 10%", "Prob: 50%", "Prob: 90%"]

for i in 1:3
    res = [ss.binom.pmf(r, 10, prob[i]) for r in 0:10]
```

```
    plt.bar(r_values, res, color=color[i], label=label[i]);
    plt.legend()
end
```

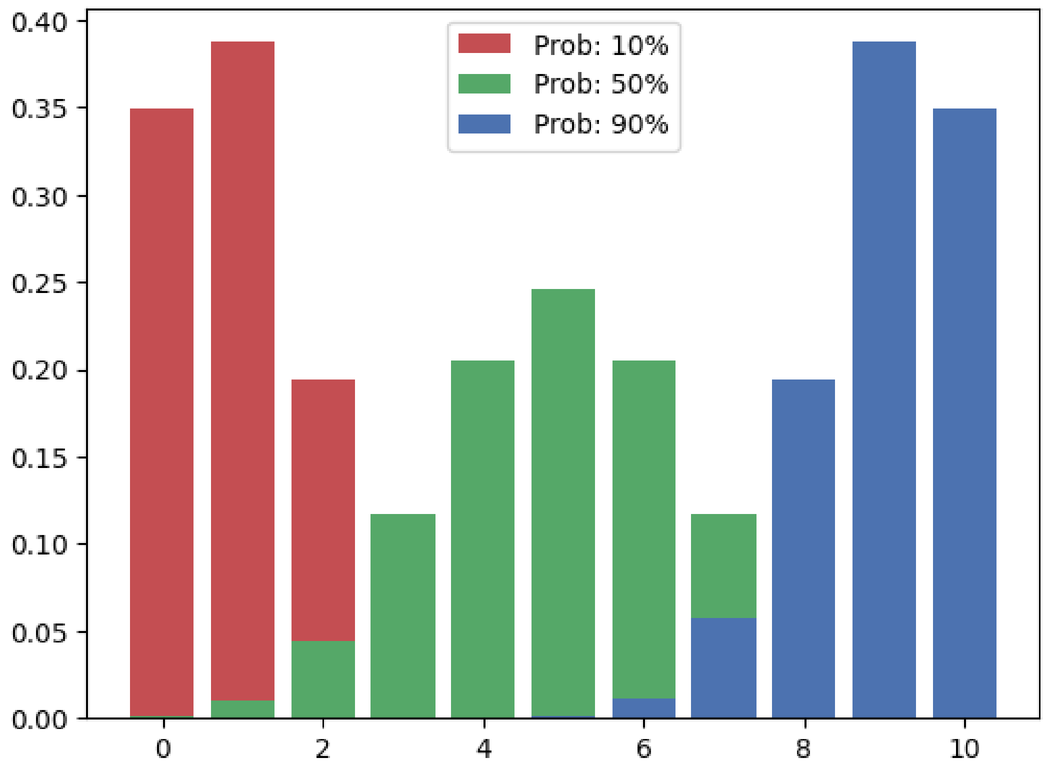

2.3.2 2.3.2 Distribuição de Poisson

Alta concentração de eventos próximos ao eixo y, uma das principais características é que não tem repetições como na distribuição binomial trabalha em um intervalo continuo.Ex: Em um estudo de chuva ou cliques em um site, no exemplo da chuva, qual é a chance de uma chuva, só que não existe o evento “não chuva” entre duas chuvas.

Imagine um intervalo, que começa e 0 até uma variável W por exemplo. E eu divido em **n** intervalos muito pequenos, onde n tende ao infinito., logo a probabilidade está tendendo a 0 pois existem n intervalinhos, com essa quantidade de intervalos, virou uma binomial, ou seja, choveu ou não por exemplo.

$$P(r/\frac{\lambda}{r}, n) = \lim_{n \to \infty} (\frac{\lambda}{n})^r.(1 - \frac{\lambda}{n})^{n-r}.\frac{n!}{r!(n-r)!}$$

Distribuição de Poisson, logo λ (Quantidade de Chuva) = p * n, então p = $\frac{\lambda}{n}$. No Limite que n tende ao infinito, o produto de **n** e **r** não vai mudar pois **r** sempre vai ficar menor e **n** sempre vai ficando maior.

$$P(r/\lambda) = \frac{e^{-\lambda} \cdot \lambda^r}{r!}$$

A média da distribuição binomial é dada pelo: λ

[11]:
```
P( , r) = np.e^-  *  ^r / np.math.factorial(r);
```

Dado que eu esperava em média 35 carros entrando no shopping, qual a probabilidade de aparecer 20?

[15]:
```
@printf "A probabilidade de somente uma chuva no mês é de: %.3f%%" P(35, 20)*100
```

```
A probabilidade de somente uma chuva no mês é de: -0.000%
```

[140]:
```
# Julia tem problema com elevar x a o espoente y
function f(x, y)
    [x*=x for _ in 1:y]
end
f(35, 20)
```

[140]:
```
20-element Vector{Int64}:
                 1225
              1500625
        2251875390625
  6616016035436858689
  7865930784382691969
 -4822766768660441855
 -1652024524321314303
   450275795304469505
 -6392656039275616255
  7551947002216534017
  3654036140188672001
  8358544585278177281
  4785494631104806913
 -2679742982427181055
  2893676706708193281
  8010019347241369601
  -482467051046174719
 -5786811055723249663
 -8394158839848501247
   541221425122377729
```

Logo em Python, aplicando a mesma função irá retornar a probabilidade de 0.0019

[14]:
```
@printf "A probabilidade de somente uma chuva no mês é de: %.3f%%" P(5, 1)*100
```

```
A probabilidade de somente uma chuva no mês é de: 3.369%
```

[895]:
```
x = ss.poisson.rvs(2, size=500);
```

[896]:
```
fig, ax = plt.subplots( figsize=(7, 4) )
ax = sns.distplot(x, color="m", hist=false, label="Poisson");
ax.vlines( np.mean(x), 0, 0.27, color="k", linestyle="--", label="Média" )
ax.vlines( np.median(x), 0, 0.27, color="c", linestyle="--", label="Mediana" )
ax.vlines( 0, -0.05, 0.28, color="#12004f", linewidth=2, linestyle="-")
ax.hlines( -0.001, -1.7, 8.5, color="#12004f", linewidth=2, linestyle="-")
ax.set_xlabel("Contagem");
ax.set_ylabel("Densidade");
ax.set_title("Distribuição Poisson")
ax.legend();
```

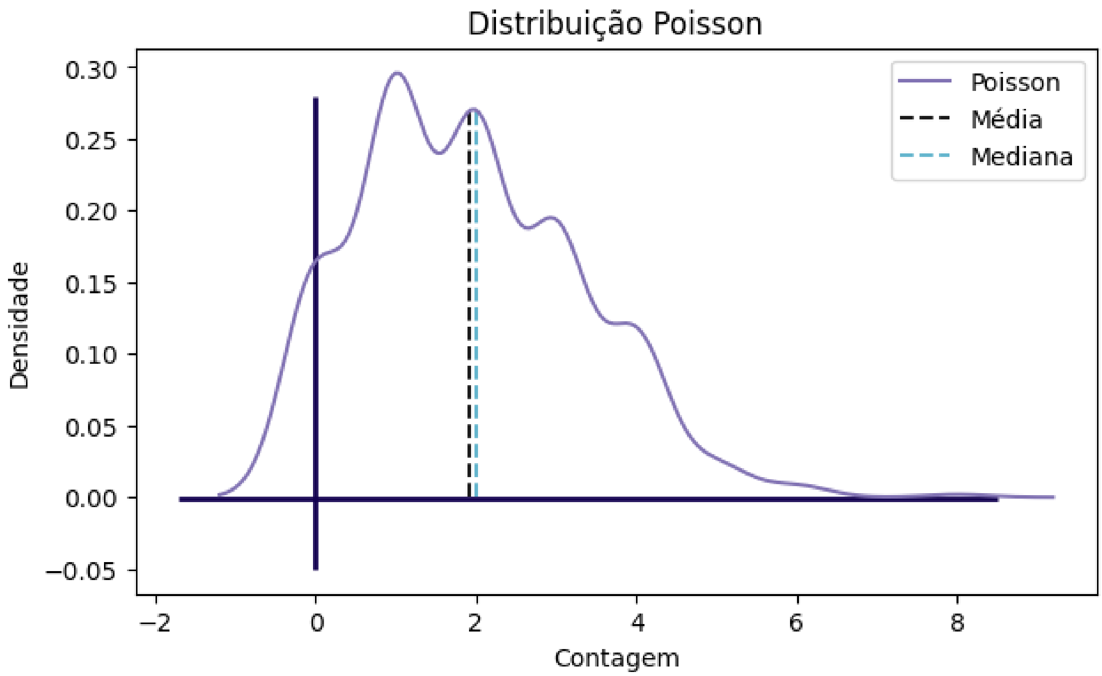

2.3.3 2.3.5 Distribuição Normal

A distribuição Normal e simétrica a média e as outras distribuições são geralmente moldadas de forma normal. Em uma distribuição normal 68% dos dados ficam dentro de um desvio-padrão da média e 90% dos dados em dois desvios-padrões.A diferença entre a distribuição normal das outras distribuições (binomial e poisson) é que na noção de distribuição discreta e continua, ambas são distribuições discretas pois as possibilidades dos eventos eram discretos, agora x pode assumir uma probabilidade, logo a função é chamada de densidade de probabilidade.Onde para calcular a área em baixo da curva usa-se a ferramenta de Integral. ($\int_0^1 f(x)\,dx$)

[97]:

```
range = np.arange(-3, 3, 0.1)
fig, ax = plt.subplots( figsize=(7, 4) )
ax.plot(range, ss.norm.pdf(range), color="b", linewidth=2, label="Normal");
[ax.vlines(  i, 0, 0.24, color="r") for i in -1:1 if i != 0]
[ax.vlines(  i, 0, 0.055, color="r") for i in -2:2 if i != 0]
[ax.vlines(  i, 0, (0.50/(i*2.0)-.01), color="r", linestyle="--" ) for i in 1:.
↪1:1.3];
[ax.vlines(  i, 0, (0.50/(i*2.3)-.01), color="r", linestyle="--" ) for i in 1.3:
↪.1:1.6];
[ax.vlines(  i, 0, (0.50/(i*3)-.01), color="r", linestyle="--" )   for i in 1.6:
↪.1:1.9];
[ax.vlines( -i, 0, (0.50/(i*2.0)-.01), color="r", linestyle="--" ) for i in 1:.
↪1:1.3];
[ax.vlines( -i, 0, (0.50/(i*2.3)-.01), color="r", linestyle="--" ) for i in 1.3:
↪.1:1.6];
[ax.vlines( -i, 0, (0.50/(i*3)-.01), color="r", linestyle="--" )   for i in 1.6:
↪.1:1.9];
ax.hlines( .003, -4, 4, color="k")
ax.vlines( 0, 0, 0.4, color="k", linestyle="--", label="Média")
ax.vlines( 1, 0, 0.24, color="r", label="Simétrica")
ax.set_title("Distribuição Normal")
fig.legend();
```

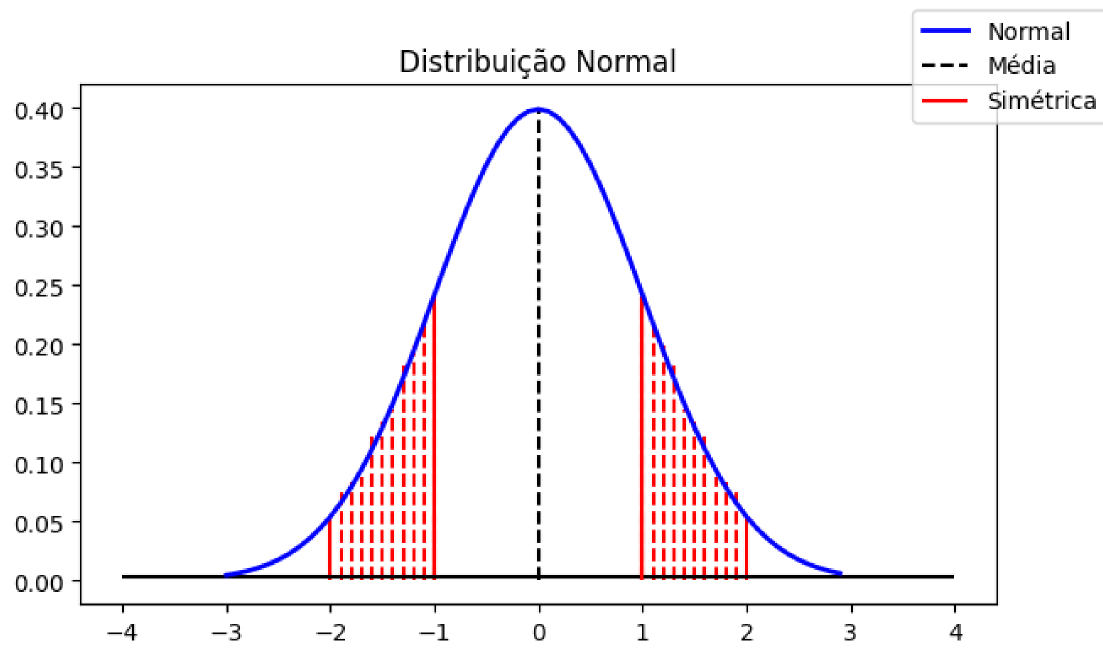

Função densidade de probabilidade

$$f(x) = \frac{1}{\sqrt{2\pi\sigma}} \cdot e^{\frac{-(x-\bar{x})^2}{2\sigma^2}}$$

[94]:
```
range = np.arange(-3, 3, 0.1)
fig, ax = plt.subplots( figsize=(7, 4) )
ax.plot(range, ss.norm.pdf(range), color="b", linewidth=2, label="Normal");
[ax.vlines(  i, 0, (0.50/(i*2.0)-.01), color="r", linestyle="--" ) for i in 1:.
↪1:1.3];
[ax.vlines(  i, 0, (0.50/(i*2.3)-.01), color="r", linestyle="--" ) for i in 1.3:
↪.1:1.6];
[ax.vlines(  i, 0, (0.50/(i*3)-.01), color="r", linestyle="--" )   for i in 1.6:
↪.1:1.9];
ax.hlines( .003, -4, 4, color="k")
ax.vlines( 0, 0, 0.4, color="k", linestyle="--", label="Média")
ax.vlines( 1, 0, 0.24, color="r", label="Simétrica")
ax.set_title("Distribuição Normal")
fig.legend();
```

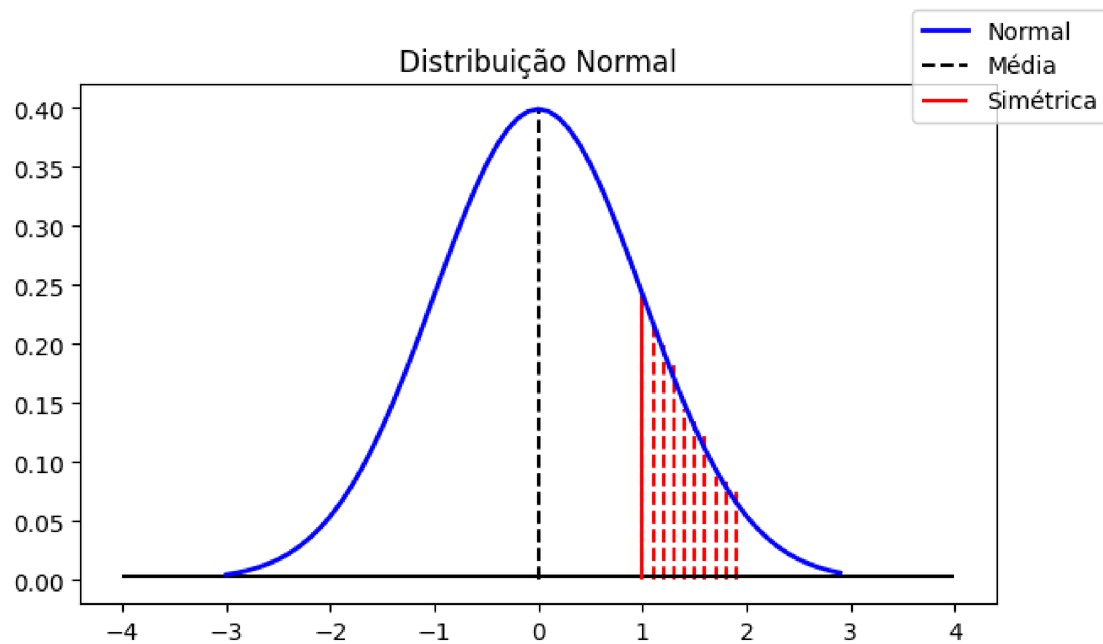

Como a variável x é continua, sendo assim pode assumir infinitos valores, e tambem toda a area da curva gaussiana é 1. Logo para calcular a área entre 1 e 2 da normal:

$$P = \int_1^2 \frac{1}{\sqrt{2\pi\sigma}} \cdot e^{\frac{-(x-\bar{x})^2}{2\sigma^2}} \, dx$$

2.3.4 2.3.6. QQ Plot

[ ]:
```
##
```

2.3.5 2.3.3 Distribuição Exponencial

A concentração dos dados em uma distribuição exponencial é diferente.

[870]:
```
x = ss.expon.rvs( 0.2, size=1000);
```

[871]:
```
fig, ax = plt.subplots( figsize=(7, 4) )
ax = sns.distplot(x, color="r", hist=false, label="Exponencial");
ax.set_xlabel("Contagem");
ax.vlines( np.mean(x), 0, 0.4, color="k", linestyle="--", label="Média" )
ax.vlines( np.median(x), 0, 0.55, color="c", linestyle="--", label="Mediana" )
ax.vlines( 0, 0, 0.7, color="#12004f", linestyle="-")
ax.vlines( 0, -0.05, 0.28, color="#12004f", linewidth=2, linestyle="-")
ax.hlines( -0.001, -1.7, 8.5, color="#12004f", linewidth=2, linestyle="-")
ax.set_title("Distribuição Exponencial")
ax.legend();
```

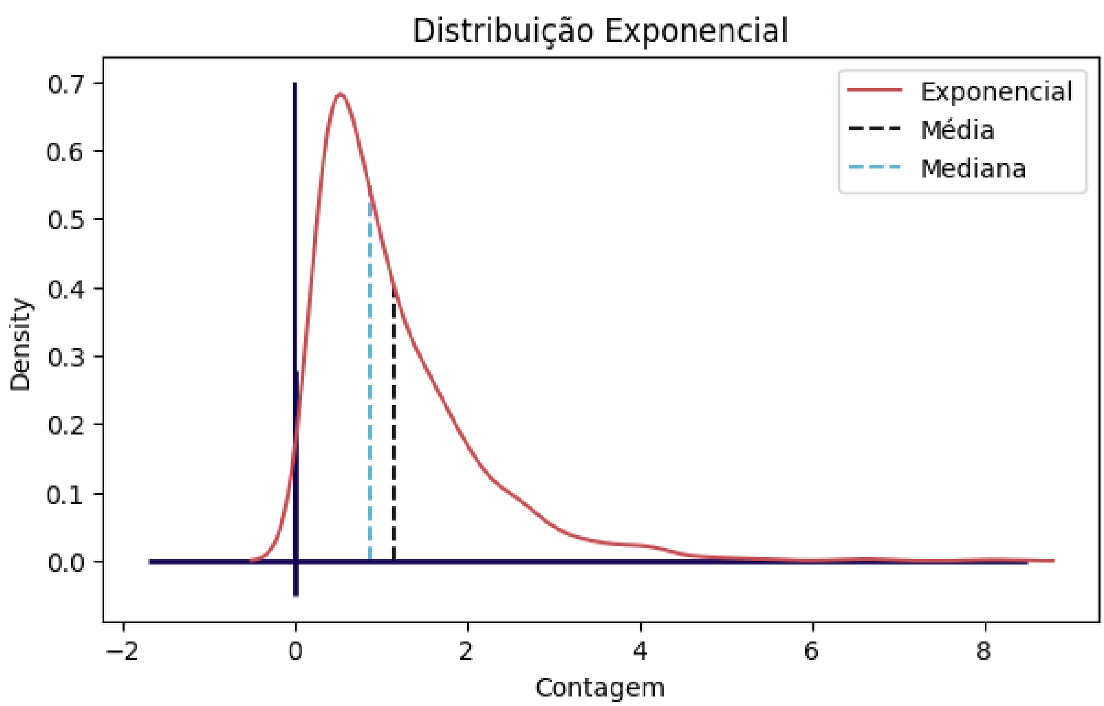

2.3.6 2.3.4 Distribuição Weibull

[12]:
```
# Melhorar Informações
```

É uma extensão da distribuição Exponencial, na qual a taxa de evento pode mudar de acordo ocm um “parâmetro de forma” Se > 1, a probabilidade de um evento aumenta com o tempo. Se < 1, a probabilidade de um evento diminui com o tempo. Sendo assim, pode ser utilizada na análise de sobrevivência & confiabilidade, e sua função é:

[86]:
```
x = ss.weibull_min.rvs(1.5, scale=5000, size=100)

fig, ax = plt.subplots( figsize=(7, 4) )
ax = sns.distplot( x, color="r", label="Weibull");
ax.hlines( -.1/(1000*100), 150*150, -200, color="#12004f", linewidth=2,␣
 ↪linestyle="-")
ax.vlines( -.1/(1000*100), -.1/(500*10), .1/(500), color="#12004f",␣
 ↪linewidth=2, linestyle="-")
ax.set_title("Distribuição Weibull")
ax.legend();
```

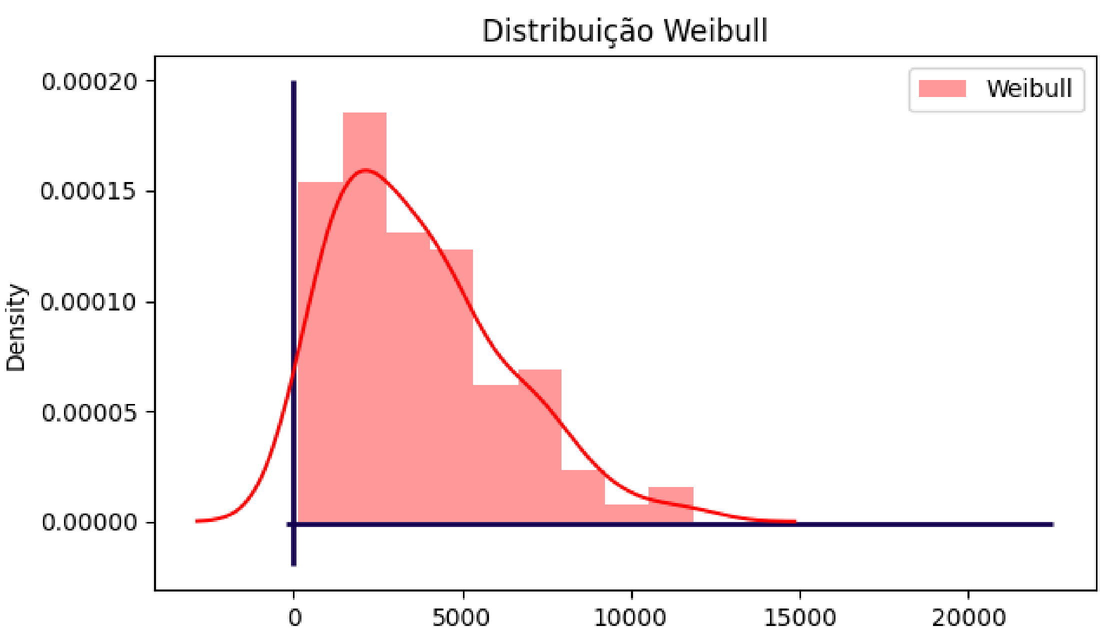

3 3.0. Capítulo 3

3.1 3.1. Teste T de Student

O teste T de Student nada mais é que um teste de comparação de dois grupos em relação a sua média.Nas quais os dados são numéricos, mas para que seja utilizado é necessário usar uma forma padronizada de estatística de teste.

$$H_o : \text{A média do tempo de sessão para a página A é maior ou igual que a B}$$

$$H_a : \text{A média do tempo de sessão para a página A é menor que a B}$$

[75]:
```
df = DataFrame(CSV.File("data/web_page_data.csv"));
```

[20]:
```
fig, ax = plt.subplots( figsize=(7, 5) )
ax.hist( df[df.Page .== "Page A", 2], histtype="step", linewidth=2, color="r",␣
 ↪label="Page A")
ax.hist( df[df.Page .== "Page B", 2], histtype="step", linewidth=2, color="b",␣
 ↪label="Page B")
ax.hlines( y=2.0, xmin=-0, xmax=4., linestyle="--", color="k" )
ax.set_xlabel("Time")
ax.set_ylabel("Count")
ax.legend();
```

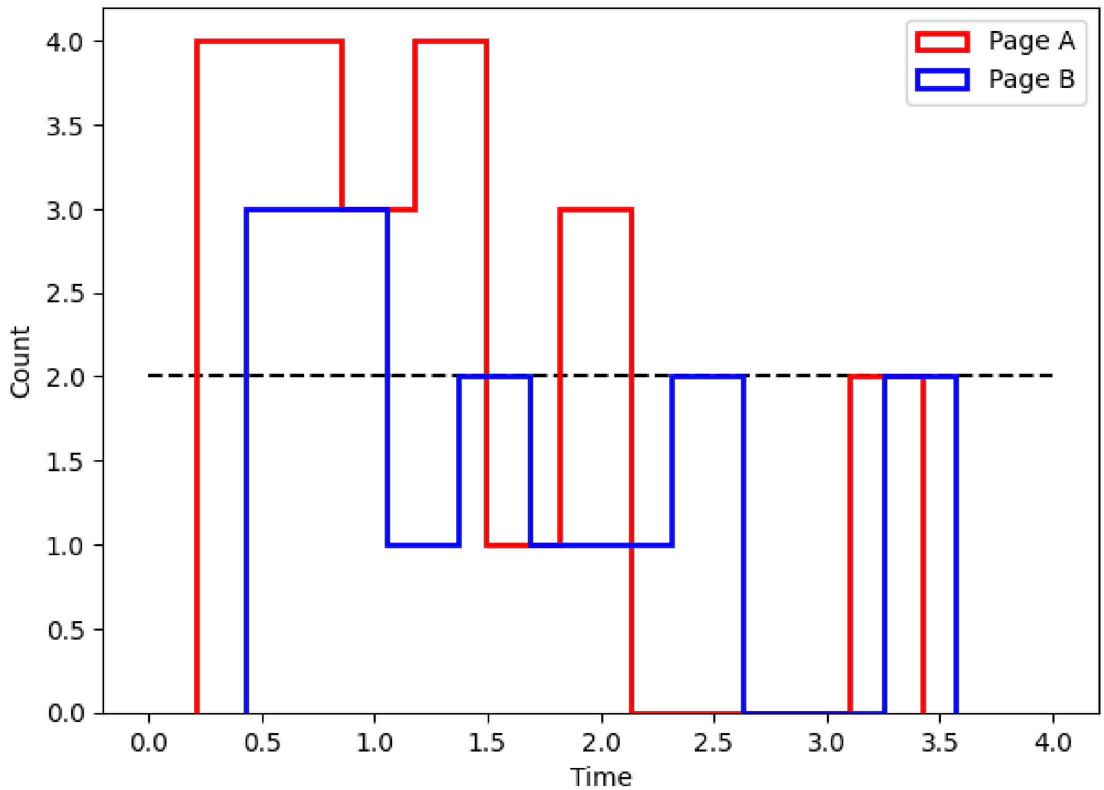

[179]:
```
list = ["less", "two-sided"]
mean_a = np.mean( df[df.Page .== "Page A", 2] )
mean_b = np.mean( df[df.Page .== "Page B", 2] )
std_a = np.std( df[df.Page .== "Page A", 2] )
std_b = np.std( df[df.Page .== "Page B", 2] )
```

```
n1 = length(df[df.Page .== "Page A", 2])
n2 = length(df[df.Page .== "Page B", 2])

for i in list
    t_test = ss.ttest_ind( df[df.Page .== "Page A", 2], df[df.Page .== "Page␣
↪B", 2], equal_var=false, alternative=i )
    if i == "less"
        @printf "P-Value One Sided %.3f\n" t_test[2]
        @printf "T-Statistic: %.3f\n" t_test[1]
    else
        @printf "\nP-Value Two Sided %.3f\n" t_test[2]
        @printf "T-Statistic: %.3f\n" t_test[1]
    end
end
```

```
P-Value One Sided 0.141
T-Statistic: -1.098

P-Value Two Sided 0.282
T-Statistic: -1.098
```

[189]:

```
pearson_r(ti, df) = √( (ti^2) / (ti^2 + df ) );
glass_delt( x_bari, x_barj, stdi ) = (x_bari - x_barj) / stdi;
cohen_d(x_bari, x_barj, stdi, stdj) = ( x_bari - x_barj ) / √( ( stdi^2 +␣
↪stdj^2 ) / 2 );
hedge_g( d, ni, nj ) = ( d * ( 1 - ( 3 / (4*(ni + nj - 9)))));

gl = glass_delt( mean_a, mean_b, std_a )
r  = pearson_r( t_test[1], 34 )
d  = cohen_d( mean_a, mean_b, std_a, std_b )
g  = hedge_g( d, n1, n2 )

@printf "Glass  : %.4f" gl
@printf "\nPearson  : %.4f" r
@printf "\nCohen's d: %.4f" d
@printf "\nHedge's g: %.4f" g
```

```
Glass  : -0.4131
Pearson  : 0.1851
Cohen's d: -0.3869
Hedge's g: -0.3761
```

- Glass : É a diferença média entre os dois grupos dividido pelo desvio padrão do grupo controle.
- Pearson : Pearson / Rosenthal serve para calcular a correlação utilizando o P Value e os Graus de Liberdade.
- Cohen's d: Diferença das médias, é uma formula do "tamanho do efeito", que resumidamente mede o tamanho das associações entre as variáveis ou da diferença entre as médias dos grupos.

- Hedge's g: Correção do D de Cohen.

```
[ ]:
```

```
[ ]:
```

```
[ ]:
```

4 x.0. Referências

PETER BRUCE & ANDREW BRUCE **Estatística prática para cientistas de dados: 50 conceitos essenciais**. Link: https://www.amazon.com.br/Estat%C3%ADstica-Pr%C3%A1tica-Para-Cientistas-Dados/dp/855080603X DAVID MATOS **8 Conceitos Estatísticos Fundamentais Para Data Science**. Link: https://www.cienciaedados.com/8-conceitos-estatisticos-fundamentais-para-data-science/IGOR SOARES **Correlação não implica em Causalidade**.Link: https://medium.com/@felipemaiapolo/correla%C3%A7%C3%A3o-n%C3%A3o-implica-em-causalidade-8459179ad1bc.annahaensch **Número de Casos de Divórcio em Maine**Link: https://blogs.ams.org/blogonmathblogs/2017/04/10/divorce-and-margarine/Wikipédia **Cramer's_V**Link: https://en.wikipedia.org/wiki/Cram%C3%A9r%27s_V